

Análisis de conglomerados y clasificación de series de tiempo. Utilizando Kullback-Liebler sobre la densidad espectral. Un ejemplo aplicado a audio de gatos y perros

Campos Martínez Joaquín Nicolás

Alumno de Actuaría

Facultad de Ciencias Actariales

Universidad Anáhuac Campus Norte

Introducción

En este practicum queremos mostrar el uso de la densidad espectral para clasificar series de tiempo, algunas de las razones que impulsaron esta idea fueron: primero, algunos ejemplos, particularmente la clasificación de temblores basada en esta misma metodología ([Shumway, 2003](#)) ([Yoshihide Kakizawa, 1998](#)), en el caso de Shumway como un medio para monitorear que se respeten las reglas internacionales de pruebas nucleares. También tenemos el caso de la clasificación de flamas según el sonido generado en la combustión. ([J. Yuan, 2000](#)). El posible uso para crear listas de reproducción automáticas.

La primera parte del texto consiste en un ejemplo de la clasificación de audios de perros y gatos que forma parte de una base de datos de 48 clases acústicas adicionales, utilizada en un artículo sobre redes neuronales ([Naoya Takahashi y Gool, 2016](#)).

La base utilizada consta de 164 archivos WAV con sonidos de gatos, maullidos, ronroneos, o similares y 113 sonidos de perros, ladridos principalmente. Decidimos seguir el ejercicio propuesto en el sitio Kaggle ([marc moreaux, 2017](#)), donde se propone dividir la muestra en conjunto de entrenamiento con 115 archivos de gatos y 64 de perros, los 49 restantes de cada categoría se asignan al conjunto de prueba. Ambos se presentan en las tablas [3](#), [4](#), [5](#), [6](#)

Los resultados preliminares son bastante satisfactorios, tasa de error del 15 %, 16 %, curva roc del 93 %, y notamos que el espectro de maullidos es muy distinto de ladridos en términos de duración y armonía.

La segunda parte del texto utiliza los mismos 277 archivos de audio utilizados en el ejemplo anterior para realizar un análisis de conglomerados, probamos 2 formas, primero presentamos resultados de un enfoque jerárquico,

y después presentamos la implementación del algoritmo de k-medias. En ambos casos los resultados son interesantes y en cierta forma congruentes con el ejemplo discriminante que realizamos, incluso podemos notar que los sonidos de gatos se pueden dividir en 2 subgrupos.

Objetivo

Nosotros queremos presentar una metodología de clasificación y conglomeración de series de tiempo basada en la estructura de correlación. Nuestra base es utilizar la medida de discrepancia de Kullback-Liebler sobre la densidad espectral para clasificar en un grupo, según el espectro medio de cada grupo y mostrar su aplicación a un problema propuesto en el sitio Kaggle.

Relevancia

Las series de tiempo pueden ser observadas en diferentes ámbitos, información de ventas, precios de acciones, tasas cambiarias, información sobre el clima, datos biomédicos, etc. ([Saeed Aghabozorgi, 2015](#))

Las aplicaciones de análisis de conglomerados en estos ámbitos son variadas, por ejemplo, en medicina es importante reconocer la diferencia entre señales normales en un ECG, EEG, EMG de aquellas producidas por enfermedades. En sismología, para discriminar las ondas sísmicas, de los movimientos naturales de la tierra ([Corduas Marcella, 2008](#)) o para monitorear violaciones al CTBT (Tratado de prohibición completa de los ensayos nucleares, en español) ([Shumway, 2003](#)).

Otras aplicaciones son, en astronomía las curvas de luz muestran el brillo de una estrella en un periodo de tiempo, en medicina la actividad cerebral, en el medio ambiente y

urbanización los niveles de la marea, niveles de contaminantes en el aire ($PM_{2.5}$, PM_{10}) (Saeed Aghabozorgi, 2015).

Antecedentes

Hay múltiples artículos sobre análisis de conglomerados, y algunos de ellos se enfocan en series de tiempo. *Time-series clustering - A decade review* (Saeed Aghabozorgi, 2015) tiene como objetivo comparar los enfoques más populares. (Saeed Aghabozorgi, 2015)

Como perros y gatos

Como dijimos nos centramos en 2 ejemplos, el primero consiste en crear una regla de clasificación de los sonidos de perros y gatos, y el segundo es realizar un análisis de conglomerados sobre la misma muestra, en ambos casos consideramos los audios como series de tiempo y les damos un tratamiento espectral, de modo que podamos aplicar la divergencia K-L sobre las densidades espectrales.

Perros vs gatos

Nuestro ejemplo está basado en un ejercicio propuesto por (marc moreaux, 2017), utilizamos 115 audios de gatos y 64 de perros para entrenar el algoritmo y 49 de cada clase para validar nuestro modelo.

Primero tenemos un problema de desbalanceo en nuestro conjunto de entrenamiento, para tener la misma cantidad de observaciones de perros como de gatos utilizamos la técnica de bootstrapping con reemplazo para sobremuestrear los 64 perros de entrenamiento, el resultado de remuestreo se muestra en la tabla 4.

Análisis exploratorio

Observemos algunas series de tiempo de gatos y perros. La figura 1 es la gráfica de series de tiempo de un maullido, es bastante sostenido, y notamos que la variación aumenta del inicio del maullido a la mitad para después bajar. Por otro lado, la figura 2 nos muestra un ladrido, en comparación es más explosivo, en el sentido de que la variación más alta es al inicio, y luego disminuye. Las gráficas de series anteriores, así como los espectrogramas siguientes corresponden a los archivos *cat_75.wav* y *dog_barking_101.wav* tomados al azar de la muestra.

Por un lado el maullido presentado en la figura 3 muestra un comportamiento armónico y con mayor duración que el ladrido de la figura 4. Esto nos lleva a pensar que podemos utilizar la densidad espectral como representación de la serie de tiempo en un análisis discriminante.

Clasificación

De (Shumway, 2003) podemos dividir el proceso de clasificación en los siguientes pasos




Figura 1: La representación gráfica de un maullido bastante nítido




Figura 2: La representación gráfica de un ladrido bastante nítido

1. Estimar la densidad espectral de cada serie de tiempo
2. Promediar las densidades espectrales por grupo o clase
3. Clasificar al grupo al cual la medida de divergencia de Kullback-Liebler sea menor




Figura 3: Espectrograma maullido




Figura 4: Espectrograma ladrado

Estimar la densidad espectral

Utilizamos la «ventana» de Tukey-Hanning ([Priestley, 1981](#)), de modo que nuestra función de densidad espectral esta dada por

$$\hat{h}(w) = \frac{1}{4}\hat{h}_0\left(w - \frac{\pi}{M}\right) + \frac{1}{2}\hat{h}_0(w) + \frac{1}{4}\hat{h}_0\left(w + \frac{\pi}{M}\right)$$

Donde \hat{h}_0 es el periodograma truncado dado por

$$\hat{h}_0 = \frac{1}{2\pi} \sum_{s=-M}^M \hat{R}(s) \cos(sw)$$

, donde a su vez $\hat{R}(s)$ es el estimador de la función de autocovarianza

$$\hat{R}(s) = \frac{1}{N} \sum_{t=1}^{N-|s|} (X_t - \bar{X})(X_{t+|s|} - \bar{X})$$

El siguiente paso es promediar las densidades espectrales por grupo

$$\bar{\hat{h}}_G(w) = \frac{1}{115} \sum_{i=1}^{115} \hat{h}_{GEi}(w)$$

$$\bar{\hat{h}}_P(w) = \frac{1}{115} \sum_{i=1}^{115} \hat{h}_{PEi}(w)$$

Donde $\hat{h}_{GEi}(w)$ es la densidad espectral de la i-ésima serie de tiempo del conjunto de entrenamiento de los gatos, análogamente $\hat{h}_{PEi}(w)$ corresponde a la i-ésima serie de tiempo del conjunto de entrenamiento de los perros.




Figura 5: Densidad espectral grupo felino




Figura 6: Densidad espectral grupo canino

Regla de clasificación

La figura 5 nos muestra la densidad espectral de los audios de gatos, podemos notar que tiene su moda en frecuencias bajas, y luego decae lentamente a 0. En cambio, la densidad espectral para ladridos, 6, tienen su moda en frecuencias medias, y decae rápidamente a 0. Ahora que tenemos nuestros espectros promedio, el siguiente paso es la regla de clasificación

$$\text{clasifica } \hat{f} \text{ en } \begin{cases} \text{Gatos si } I(\hat{h}_G, f) \leq I(\hat{h}_P, f) \\ \text{Perros si } I(\hat{h}_G, f) > I(\hat{h}_P, f) \end{cases}$$

Donde $I(f, g) = \int_x f(x) \log\left(\frac{f(x)}{g(x)}\right) dx$ es la información de Kullback (Kullback, 1978).

Los resultados de aplicar la regla de clasificación fueron 19 series fueron clasificadas en el grupo de perros, pero en realidad son sonidos de gatos, 22 sonidos de perros fueron clasificados incorrectamente en el grupo de gatos. La tasa de error fue del 18 %, sensibilidad del 83 % y especificidad del 80 %.

Para generalizar un poco más nuestra regla decidimos introducir un umbral de decisión K , en nuestro caso no hay ninguna pérdida asociada con clasificar erróneamente en una clase o en la otra, de modo que decidimos escoger K con el criterio minimax.

| | Gato | Perro |
|-------|------|-------|
| Gatos | 96 | 19 |
| Perro | 22 | 93 |

Cuadro 1: Matriz de confusión conjunto de entrenamiento

$$\text{clasifica } \hat{f} \text{ en } \begin{cases} \text{Gatos si } K \leq I(\hat{h}_P, f) - I(\hat{h}_G, f) \\ \text{Perros si } K > I(\hat{h}_P, f) - I(\hat{h}_G, f) \end{cases}$$

El criterio minimax consiste en escoger K de modo que

$$\text{espec}(K) = \text{sens}(K)$$

donde $\text{espec}(K) = \frac{\text{Verdaderos negativos}}{\text{Total negativos}}$ y $\text{sens}(K) = \frac{\text{Verdaderos positivos}}{\text{Total positivos}}$. Dado que la estructura del problema es no paramétrica encontrar K se vuelve un problema numérico, por esto corrimos valores del umbral entre -5 y 5 , con saltos de $.1$, encontrando que nuestro mejor valor fue $K = 0$. Entonces nuestra regla sigue siendo la misma que al inicio.

Si aplicamos la regla de clasificación con el umbral al conjunto de entrenamiento tenemos una tasa de error del 13 %, y la matriz de confusión 2, la sensibilidad fue 81 % y la especificidad aumento al 93 %. Resultados bastante estables.

| | Gato | Perro |
|-------|------|-------|
| Gatos | 40 | 9 |
| Perro | 3 | 46 |

Cuadro 2: Matriz de confusión conjunto de prueba

Recordando que la muestra incluye «sonidos similares a gatos y perros», es natural que algunos sonidos queden erróneamente clasificados. Por ejemplo, algunas observaciones suenan como discos rayados (cat_167.wav y cat_165.wav, del conjunto de entrenamiento), u observaciones que incluyen ladridos y maullidos (cat_97.wav, cat_98.wav, cat_99.wav). Otras simplemente carecen de maullido o ladrido y son ruido de fondo (dog_barking_107.wav, dog_barking_109.wav).

La curva ROC del conjunto de prueba, tomando a los gatos como la clase de «positivos», el resultado es bastante satisfactorio con un AUN del 93 %

Análisis de conglomerados

El análisis de conglomerados es una técnica de análisis exploratorio, que busca separar la muestra en




Figura 7: Curva ROC del conjunto de prueba




Figura 8: Dendrograma enlace completo

grupos(William R. Dillon, 1984). Hay dos enfoques muy conocidos para el análisis de conglomerados, el primero es jerárquico y el segundo es k-means.

En el caso del jerárquico nos centraremos en algoritmos aglomerativos, esto es, cada observación comienza como un conglomerado, un grupo por si mismo, y en cada paso se une un conglomerado con otro según la distancia entre uno y el otro.

El enfoque de k-means (o k-medias) consiste en escoger un número de grupos seleccionar centros al azar y clasificar al centro más cercano, recalculando el centro y repetir hasta que no suceda cambio alguno.

Enfoque jerárquico

Los algoritmos jerárquicos aglomerativos parten de una matriz de «distancias» entre observaciones con entradas

$$D_{ij} = J(\hat{h}_i, \hat{h}_j)$$

donde $J(\hat{h}_i, \hat{h}_j) = I(\hat{h}_i, \hat{h}_j) + I(\hat{h}_j, \hat{h}_i)$. La métrica J cumple las propiedades de una distancia, exceptuando la desigualdad del triángulo.

Algunos métodos requieren definir distancias entre conglomerados, métodos de enlace completo y singular. Y otros reducir una función objetivo como lo es el método de Ward.

En la figura 8 presentamos el dendrograma que resulta de aplicar la metodología de enlace completo. Los puntos

inferiores indican a que clase pertenecen las observaciones. Los puntos color vino indican **gatos** y los puntos azules **perros**, notamos que las observaciones están muy mezcladas, esto es, si hacemos un corte a 3 conglomerados tendríamos un conglomerado con una mezcla 124 observaciones de gatos con 111 de perros. Incluso si cortamos a 5 conglomerados, habría un conglomerado 63 gatos y 97 perros.




Figura 9: Dendrograma Ward

Otra método es mínima varianza de Ward, el cual consiste en agregar conglomerados de tal modo que el aumento en la suma de errores cuadráticos de cada observación a la media del conglomerado al que pertenecen sea mínima. Es decir, busca minimizar el incremento en la siguiente función objetivo

$$\sum_{k=1}^n \sum_{i=1}^{n_k} \sum_{j=1}^{n_k} d(x_i, x_j)^2 = \sum_{k=1}^n \sum_{i=1}^{n_k} d(x_i, \bar{x}_k)^2$$

Donde k es el número conglomerados, n_k el número de elementos en el conglomerado. Ahora bien, la igualdad no cumple para cualquier distancia d , particularmente es valida para la distancia euclidiana.

La figura 9 presenta el dendograma que resulta de aplicar esta metodología y los cambios se presentan en la tabla , donde notamos que hay tres conglomerados donde predominan los mininos, y otro donde predominan los perros, pero contiene mezclado 24 gatos.

| | | | | |
|-------|----|----|----|----|
| | 1 | 2 | 3 | 4 |
| Gatos | 24 | 49 | 76 | 15 |
| Perro | 99 | 1 | 9 | 4 |

De esos gatos que se cuelan en el grupo 1 algunos tienen características como discos rayados (cat_167.wav, cat_165.wav), o combinaciones con otros sonidos, tienen mucho ruido (cat_81.wav, cat_82.wav). Si gráficos la densidad espectral del grupo 1, figura 10, notamos que es muy similar a la que obtuvimos del conjunto de entrenamiento en el ejercicio de clasificación, figura 6.

En cambio, si observamos las densidades espectrales de los grupos 2 y 3, figuras 11 y 12 respectivamente, parece que se descompone el resultado del conjunto de entrenamiento de los gatos, figura 5, en 2 partes, e incluso si obtenemos el espectro promedio al juntar los 2 grupos, figura 13, tiene una forma más parecida a 5. Esto sugiere que el grupo de gatos puede tener 2 subgrupos con características distintas, ronroneos y maullidos. O gatos chicos y mayores.[por actualizar y verificar].

K-medias

El algoritmo de k-medias consiste en escoger el número de grupos k . El siguiente paso es escoger k de los elementos de la muestra, y tomarlos como centros, $\hat{\mu}_{s1} = \hat{h}_r$, donde $\hat{\mu}_{s1}$ es el centro del s -ésimo conglomerado en la primera iteración y \hat{h}_r es el estimador de la densidad espectral de la r -ésimo serie de tiempo.

El siguiente paso es clasificar en el centro más cercano esto es clasificar \hat{f} en el conglomerado s si

$$I(\hat{\mu}_{s1}, f) \leq I(\hat{\mu}_{j1}, f), j = 1, \dots, k$$




Figura 10: Espectro conglomerado 1




Figura 11: Espectro conglomerado 2

Luego debemos obtener recalculamos las medias

$$\hat{\mu}_{s2} = \sum_{i=1}^{n_s} \hat{h}_s i$$

donde $\hat{\mu}_{s2}$ es el centro del s -ésimo conglomerado en la segunda iteración, $\hat{h}_s i$ es la densidad espectral de la i -ésima serie de tiempo en el s -ésimo conglomerado. Se reclasifican

El primer conglomerado tiene un aspecto similar a la respectiva con el grupo de gatos, y la segunda con el grupo de perros.




Figura 12: Espectro conglomerado 3




Figura 14: Densidad conglomerado 1




Figura 13: Espectro conglomerados 2 y 3 juntos

a los centros más cercanos. Repetimos estos pasos hasta que no haya cambios en la clasificación.

Para nuestro ejemplo, tomamos $k = 2$ para observar si el análisis de conglomerados separa en las 2 clases originales gatos y perros. Las figura 14 y 15 muestran las densidades espectrales del conglomerado 1 y el conglomerado 2 respectivamente.




Figura 15: Densidad conglomerado 2

Lo anterior se reafirma observando la clasificación resultante, un conglomerado con 128 gatos y 12 perros, y otro compuesto de 101 perros y 36 gatos, si midieramos la tasa de error sería del 20% .

Referencias

- Corduas Marcella, P. D. (2008). *Time series clustering and classification by the autoregressive metric*.
- J. Yuan, Y. Z. (2000). *Spectral analysis of combustion noise and flame pattern recognition*.
- Kullback, S. (1978). *Information theory and statistics*. Dover Publications.
- marc moreaux. (2017). *Audio cats and dogs, classify raw sound events*. <https://www.kaggle.com/mmmoreaux/audio-cats-and-dogs/home>. ([Online; Obtenido 04-Noviembre-2018])
- Naoya Takahashi, B. P., Michael Gygli, y Gool, L. V. (2016). *Deep convolutional neural networks and data augmentation for acoustic event recognition*.
- Priestley, M. B. (1981). *Spectral analysis and time series*. Academic Press.
- Saeed Aghabozorgi, T. Y. W., Ali Seyed Shirkhorshidi. (2015). *Time-series clustering – a decade review*.
- Shumway, R. H. (2003). *Time-frequency clustering and discrimination analysis*.
- William R. Dillon, M. G. (1984). *Multivariate analysis*. Wiley.
- Yoshihide Kakizawa, M. T., Robert H. Shumway. (1998). *Discrimination and clustering for multivariate time series*.

1. Anexo 1, muestra

| | | |
|--------------------|--------------------|--------------------|
| cat_1.wav | cat_10.wav | cat_100.wav |
| cat_101.wav | cat_102.wav | cat_105.wav |
| cat_107.wav | cat_108.wav | cat_109.wav |
| cat_11.wav | cat_110.wav | cat_113.wav |
| cat_114.wav | cat_115.wav | cat_118.wav |
| cat_119.wav | cat_121.wav | cat_122.wav |
| cat_123.wav | cat_124.wav | cat_126.wav |
| cat_127.wav | cat_128.wav | cat_129.wav |
| cat_130.wav | cat_131.wav | cat_132.wav |
| cat_133.wav | cat_134.wav | cat_135.wav |
| cat_137.wav | cat_139.wav | cat_14.wav |
| cat_140.wav | cat_142.wav | cat_143.wav |
| cat_146.wav | cat_147.wav | cat_148.wav |
| cat_15.wav | cat_151.wav | cat_152.wav |
| cat_153.wav | cat_154.wav | cat_156.wav |
| cat_157.wav | cat_158.wav | cat_159.wav |
| cat_16.wav | cat_161.wav | cat_162.wav |
| cat_163.wav | cat_164.wav | cat_165.wav |
| cat_167.wav | cat_17.wav | cat_18.wav |
| cat_19.wav | cat_23.wav | cat_25.wav |
| cat_26.wav | cat_27.wav | cat_28.wav |
| cat_3.wav | cat_30.wav | cat_31.wav |
| cat_32.wav | cat_33.wav | cat_34.wav |
| cat_35.wav | cat_36.wav | cat_37.wav |
| cat_39.wav | cat_4.wav | cat_40.wav |
| cat_41.wav | cat_42.wav | cat_43.wav |
| cat_44.wav | cat_48.wav | cat_51.wav |
| cat_54.wav | cat_56.wav | cat_57.wav |
| cat_6.wav | cat_61.wav | cat_62.wav |
| cat_64.wav | cat_68.wav | cat_69.wav |

| | | |
|-------------------|-------------------|-------------------|
| cat_7.wav | cat_71.wav | cat_72.wav |
| cat_73.wav | cat_75.wav | cat_76.wav |
| cat_78.wav | cat_79.wav | cat_80.wav |
| cat_81.wav | cat_82.wav | cat_84.wav |
| cat_85.wav | cat_86.wav | cat_87.wav |
| cat_88.wav | cat_90.wav | cat_91.wav |
| cat_92.wav | cat_93.wav | cat_95.wav |
| cat_96.wav | cat_97.wav | cat_98.wav |
| cat_99.wav | | |

Cuadro 3: Gatos en el conjunto de entrenamiento

| | |
|----------------------------|----------------------------|
| dog_barking_101.wav | dog_barking_102.wav |
| dog_barking_105.wav | dog_barking_107.wav |
| dog_barking_108.wav | dog_barking_110.wav |
| dog_barking_111.wav | dog_barking_12.wav |
| dog_barking_13.wav | dog_barking_14.wav |
| dog_barking_16.wav | dog_barking_17.wav |
| dog_barking_19.wav | dog_barking_2.wav |
| dog_barking_20.wav | dog_barking_22.wav |
| dog_barking_23.wav | dog_barking_24.wav |
| dog_barking_25.wav | dog_barking_27.wav |
| dog_barking_29.wav | dog_barking_30.wav |
| dog_barking_31.wav | dog_barking_33.wav |
| dog_barking_36.wav | dog_barking_37.wav |
| dog_barking_4.wav | dog_barking_41.wav |
| dog_barking_45.wav | dog_barking_46.wav |
| dog_barking_49.wav | dog_barking_50.wav |
| dog_barking_53.wav | dog_barking_54.wav |
| dog_barking_55.wav | dog_barking_56.wav |
| dog_barking_58.wav | dog_barking_59.wav |
| dog_barking_6.wav | dog_barking_62.wav |
| dog_barking_66.wav | dog_barking_67.wav |

| | |
|----------------------------|----------------------------|
| dog_barking_68.wav | dog_barking_7.wav |
| dog_barking_72.wav | dog_barking_74.wav |
| dog_barking_75.wav | dog_barking_76.wav |
| dog_barking_79.wav | dog_barking_80.wav |
| dog_barking_81.wav | dog_barking_83.wav |
| dog_barking_84.wav | dog_barking_85.wav |
| dog_barking_86.wav | dog_barking_87.wav |
| dog_barking_88.wav | dog_barking_89.wav |
| dog_barking_9.wav | dog_barking_90.wav |
| dog_barking_91.wav | dog_barking_95.wav |
| dog_barking_98.wav | dog_barking_99.wav |
| <u>dog_barking_4.wav</u> | <u>dog_barking_72.wav</u> |
| <u>dog_barking_14.wav</u> | <u>dog_barking_89.wav</u> |
| <u>dog_barking_12.wav</u> | <u>dog_barking_99.wav</u> |
| <u>dog_barking_66.wav</u> | <u>dog_barking_30.wav</u> |
| dog_barking_108.wav | <u>dog_barking_25.wav</u> |
| <u>dog_barking_29.wav</u> | <u>dog_barking_33.wav</u> |
| <u>dog_barking_95.wav</u> | <u>dog_barking_59.wav</u> |
| <u>dog_barking_72.wav</u> | <u>dog_barking_14.wav</u> |
| <u>dog_barking_55.wav</u> | <u>dog_barking_75.wav</u> |
| <u>dog_barking_49.wav</u> | <u>dog_barking_75.wav</u> |
| <u>dog_barking_105.wav</u> | <u>dog_barking_45.wav</u> |
| <u>dog_barking_110.wav</u> | <u>dog_barking_14.wav</u> |
| <u>dog_barking_25.wav</u> | <u>dog_barking_27.wav</u> |
| dog_barking_108.wav | <u>dog_barking_59.wav</u> |
| <u>dog_barking_55.wav</u> | dog_barking_22.wav |
| <u>dog_barking_84.wav</u> | <u>dog_barking_31.wav</u> |
| dog_barking_22.wav | dog_barking_111.wav |
| <u>dog_barking_85.wav</u> | <u>dog_barking_37.wav</u> |
| <u>dog_barking_91.wav</u> | <u>dog_barking_33.wav</u> |
| <u>dog_barking_16.wav</u> | <u>dog_barking_12.wav</u> |
| <u>dog_barking_74.wav</u> | <u>dog_barking_23.wav</u> |
| <u>dog_barking_58.wav</u> | <u>dog_barking_76.wav</u> |
| <u>dog_barking_56.wav</u> | <u>dog_barking_25.wav</u> |
| <u>dog_barking_99.wav</u> | <u>dog_barking_74.wav</u> |
| dog_barking_107.wav | <u>dog_barking_74.wav</u> |
| <u>dog_barking_13.wav</u> | |

Cuadro 4: Perros en el conjunto de entrenamiento, los archivos subrayados son los resultados del remuestreo.

| | | |
|--------------------|-------------------|--------------------|
| cat_103.wav | cat_106.wav | cat_112.wav |
| cat_116.wav | cat_117.wav | cat_12.wav |
| cat_120.wav | cat_125.wav | cat_13.wav |
| cat_136.wav | cat_138.wav | cat_141.wav |
| cat_144.wav | cat_149.wav | cat_150.wav |
| cat_155.wav | cat_160.wav | cat_166.wav |
| cat_2.wav | cat_20.wav | cat_21.wav |
| cat_22.wav | cat_24.wav | cat_29.wav |
| cat_38.wav | cat_45.wav | cat_46.wav |
| cat_47.wav | cat_49.wav | cat_5.wav |
| cat_50.wav | cat_52.wav | cat_53.wav |
| cat_55.wav | cat_58.wav | cat_59.wav |
| cat_60.wav | cat_63.wav | cat_65.wav |
| cat_66.wav | cat_67.wav | cat_70.wav |
| cat_74.wav | cat_77.wav | cat_8.wav |
| cat_83.wav | cat_89.wav | cat_9.wav |
| cat_94.wav | | |

Cuadro 5: Gatos en el conjunto de prueba

| | |
|---------------------------|----------------------------|
| dog_barking_0.wav | dog_barking_1.wav |
| dog_barking_10.wav | dog_barking_100.wav |
| dog_barking_103.wav | dog_barking_104.wav |
| dog_barking_106.wav | dog_barking_109.wav |
| dog_barking_11.wav | dog_barking_112.wav |
| dog_barking_15.wav | dog_barking_18.wav |
| dog_barking_21.wav | dog_barking_26.wav |
| dog_barking_28.wav | dog_barking_3.wav |
| dog_barking_32.wav | dog_barking_34.wav |
| dog_barking_35.wav | dog_barking_38.wav |
| dog_barking_39.wav | dog_barking_40.wav |
| dog_barking_42.wav | dog_barking_43.wav |
| dog_barking_44.wav | dog_barking_47.wav |
| dog_barking_48.wav | dog_barking_5.wav |
| dog_barking_51.wav | dog_barking_52.wav |
| dog_barking_57.wav | dog_barking_60.wav |
| dog_barking_61.wav | dog_barking_63.wav |
| dog_barking_64.wav | dog_barking_65.wav |
| dog_barking_69.wav | dog_barking_70.wav |
| dog_barking_71.wav | dog_barking_73.wav |
| dog_barking_77.wav | dog_barking_78.wav |
| dog_barking_8.wav | dog_barking_82.wav |
| dog_barking_92.wav | dog_barking_93.wav |
| dog_barking_94.wav | dog_barking_96.wav |
| dog_barking_97.wav | |

Cuadro 6: Perros en el conjunto de prueba