

Análisis de conglomerados y clasificación de series de tiempo. Utilizando Kullback-Liebler sobre la densidad espectral. Un ejemplo aplicado a audio de gatos y perros

Campos Martínez Joaquín Nicolás

Alumno de Actuaría

Facultad de Ciencias Actariales

Universidad Anáhuac Campus Norte

Introducción

En este practicum queremos mostrar el uso de la densidad espectral para clasificar series de tiempo, algunas de las razones que impulsaron esta idea fueron: primero, algunos ejemplos, particularmente la clasificación de temblores basada en esta misma metodología ([Shumway, 2003](#)) ([Yoshihide Kakizawa, 1998](#)), en el caso de Shumway como un medio para monitorear que se respeten las reglas internacionales de pruebas nucleares. También tenemos el caso de la clasificación de flamas según el sonido generado en la combustión ([J. Yuan, 2000](#)).

La primera parte del texto consiste en un ejemplo de la clasificación de audios de perros y gatos que forma parte de una base de datos de 48 clases acústicas adicionales, utilizada en un artículo sobre redes neuronales ([Naoya Takahashi y Gool, 2016](#)).

La base utilizada consta de 164 archivos WAV con sonidos de gatos, maullidos, ronroneos, o similares y 113 sonidos de perros, ladridos principalmente. Decidimos seguir el ejercicio propuesto en el sitio Kaggle ([marc moreaux, 2017](#)), donde se propone dividir la muestra en conjunto de entrenamiento con 115 archivos de gatos y 64 de perros, los 49 restantes de cada categoría se asignan al conjunto de prueba. Ambos se presentan en las tablas

Los resultados preliminares son bastante satisfactorios, tasa de error del 15 %, 16 %, curva roc del 93 %, y notamos que el espectro de maullidos es muy distinto de ladridos en términos de duración y armonía.

La segunda parte del texto utiliza los mismos 277 archivos de audio utilizados en el ejemplo anterior para realizar un análisis de conglomerados, probamos 2 formas, primero presentamos resultados de un enfoque jerárquico, y después presentamos la implementación del algoritmo de k-medias. En ambos casos los resultados son interesantes y

en cierta forma congruentes con el ejemplo discriminante que realizamos, incluso podemos notar que los sonidos de gatos se pueden dividir en 2 subgrupos.

Objetivo

Nosotros queremos presentar una metodología de clasificación y conglomeración de series de tiempo basada en la estructura de correlación. Nuestra base es utilizar la medida de discrepancia de Kullback-Liebler sobre la densidad espectral para clasificar en un grupo, según el espectro medio de cada grupo y mostrar su aplicación a un problema propuesto en el sitio Kaggle.

Relevancia

Las series de tiempo pueden ser observadas en diferentes ámbitos, información de ventas, precios de acciones, tasas cambiarias, información sobre el clima, datos biomédicos, etc. ([Saeed Aghabozorgi, 2015](#))

Las aplicaciones de análisis de conglomerados en estos ámbitos son variadas, por ejemplo, en medicina es importante reconocer la diferencia entre señales normales en un ECG, EEG, EMG de aquellas producidas por enfermedades. En sismología, para discriminar las ondas sísmicas, de los movimientos naturales de la tierra ([Corduas Marcella, 2008](#)) o para monitorear violaciones al CTBT (Tratado de prohibición completa de los ensayos nucleares, en español) ([Shumway, 2003](#)).

Otras aplicaciones son, en astronomía las curvas de luz muestran el brillo de una estrella en un periodo de tiempo, en medicina la actividad cerebral, en el medio ambiente y urbanización los niveles de la marea, niveles de contaminantes en el aire ($PM_{2.5}$, PM_{10}) ([Saeed Aghabozorgi, 2015](#)).

Antecedentes

Hay múltiples artículos sobre análisis de conglomerados, y algunos de ellos se enfocan en series de tiempo. *Time-series clustering - A decade review* (Saeed Aghabozorgi, 2015) tiene como objetivo comparar los enfoques más populares. (Saeed Aghabozorgi, 2015)

Como perros y gatos

Como dijimos nos centramos en 2 ejemplos, el primero consiste en crear una regla de clasificación de los sonidos de perros y gatos, y el segundo es realizar un análisis de conglomerados sobre la misma muestra, en ambos casos damos consideramos los audios como series de tiempo y les damos un tratamiento espectral, de modo que podamos aplicar la divergencia K-L sobre las densidades espectrales.

Perros vs gatos

Nuestro ejemplo está basado en un ejercicio propuesto por (marc moreaux, 2017), utilizamos 115 audios de gatos y 64 de perros para entrenar el algoritmo y 69 de cada clase para validar nuestro modelo.

Primero tenemos un problema de desbalanceo en nuestro conjunto de entrenamiento, para tener la misma cantidad de observaciones de perros como de gatos utilizamos la técnica de bootstrapping con reemplazo para sobremuestrear los 64 perros de entrenamiento, el resultado de remuestreo se muestra en la tabla

Análisis exploratorio

Observemos algunas series de tiempo de gatos y perros. La figura 1 es la gráfica de series de tiempo de un maullido, es bastante sostenido, y notamos que la variación aumenta del inicio del maullido a la mitad para después bajar. Por otro lado, la figura 2 nos muestra un ladrido, en comparación es más explosivo, en el sentido de que la variación más alta es al inicio, y luego disminuye. Las gráficas de series anteriores, así como los espectrogramas siguientes corresponden a los archivos *cat_75.wav* y *dog_barking_101.wav* tomados al azar de la muestra.

Por un lado el maullido presentado en la figura 3 muestra un comportamiento armónico y con mayor duración que el ladrido de la figura 4. Esto nos lleva a pensar que podemos utilizar la densidad espectral como representación de la serie de tiempo en un análisis discriminante.

Clasificación

De (Shumway, 2003) podemos dividir el proceso de clasificación en los siguientes pasos

1. Estimar la densidad espectral de cada serie de tiempo
2. Promediar las densidades espectrales por grupo o clase




Figura 1: La representación gráfica de un maullido bastante nítido




Figura 2: La representación gráfica de un ladrido bastante nítido

3. Clasificar al grupo al cual la medida de divergencia de Kullback-Liebler sea menor

Estimar la densidad espectral

Utilizamos la «ventana» de Tukey-Hanning (Priestley, 1981), de modo que nuestra función de densidad espectral




Figura 3: Espectrograma maullido

Donde \hat{h}_0 es el periodograma truncado dado por

$$\hat{h}_0 = \frac{1}{2\pi} \sum_{s=-M}^M \hat{R}(s) \cos(sw)$$

, donde a su vez $\hat{R}(s)$ es el estimador de la función de autocovarianza

$$\hat{R}(s) = \frac{1}{N} \sum_{t=1}^{N-|s|} (X_t - \bar{X})(X_{t+|s|} - \bar{X})$$

El siguiente paso es promediar las densidades espectrales por grupo

$$\bar{\hat{h}}_G(w) = \frac{1}{115} \sum_{i=1}^{115} \hat{h}_{GEi}(w)$$




Figura 4: Espectrograma ladrido

Donde $\hat{h}_{GEi}(w)$ es la densidad espectral de la i-ésima serie de tiempo del conjunto de entrenamiento de los gatos, análogamente $\hat{h}_{PEi}(w)$ corresponde a la i-ésima serie de tiempo del conjunto de entrenamiento de los perros.




Figura 5: Densidad espectral grupo felino

esta dada por

$$\hat{h}(w) = \frac{1}{4} \hat{h}_0\left(w - \frac{\pi}{M}\right) + \frac{1}{2} \hat{h}_0(w) + \frac{1}{4} \hat{h}_0\left(w + \frac{\pi}{M}\right)$$




Figura 6: Densidad espectral grupo canino

Regla de clasificación

La figura 6 nos muestra la densidad espectral de los audios de gatos, podemos notar que tiene su moda en frecuencias bajas, y luego decae lentamente a 0. En cambio, la densidad espectral para ladridos, 6, tienen su moda en frecuencias medias, y decae rápidamente a 0. Ahora que tenemos nuestros espectros promedio, el siguiente paso es la regla de clasificación

Donde $I(f, g) = \int_x f(x) \log\left(\frac{f(x)}{g(x)}\right) dx$ es la información de Kullback (Kullback, 1978).

Los resultados de aplicar la regla de clasificación fueron 19 series fueron clasificadas en el grupo de perros, pero en realidad son sonidos de gatos, 22 sonidos de perros fueron clasificados incorrectamente en el grupo de gatos. La tasa de error fue del 18 %.

	Gato	Perro
Gatos	96	19
Perro	22	93

Para generalizar un poco más nuestra regla decidimos introducir un umbral de decisión K , en nuestro caso no hay ninguna pérdida asociada con clasificar erróneamente en una clase o en la otra, de modo que queremos escoger K tal que la tasa de error sea el menor. Dado que la estructura del problema es no paramétrica encontrar K se vuelve un problema numérico, por esto corrimos valores del umbral entre -5 y 5 , con saltos de $.1$, encontrando que nuestro mejor valor fue $K = .1$

$$\text{clasifica } \hat{f} \text{ en } \begin{cases} \text{Gatos si } K \leq I(\hat{h}_P, f) - I(\hat{h}_G, f) \\ \text{Perros si } K > I(\hat{h}_P, f) - I(\hat{h}_G, f) \end{cases}$$

La matriz de confusión resultante fue ??, y la tasa de error bajo a 15 %

	Gato	Perro
Gatos	93	22
Perro	14	93

Si aplicamos la regla de clasificación con el umbral $K = .1$ al conjunto de entrenamiento tenemos una tasa de error del 16 %, y la matriz de confusión ??, podemos notar que el error de clasificación de gatos incremento del 19 % a 26 % entre el conjunto de entrenamiento y el de prueba, mientras que el de los perros disminuyó de 12 % a 4 %. Esto nos indica que nuestra regla de clasificación tiene un sesgo de clasificar correctamente perros pero perdiendo gatos en el proceso.

	Gato	Perro
Gatos	36	13
Perro	3	46

Recordando que la muestra incluye «sonidos similares a gatos y perros», es natural que algunos sonidos queden erróneamente clasificados. Por ejemplo, algunas observaciones suenan como discos rayados (cat_167.wav y cat_165.wav, del conjunto de entrenamiento), u observaciones que incluyen ladridos y maullidos (cat_97.wav, cat_98.wav, cat_99.wav). Otras simplemente carecen de maullido o ladrido y son ruido de fondo (dog_barking_107.wav, dog_barking_109.wav).

La curva ROC del conjunto de prueba, tomando a los gatos como la clase de «positivos», el resultado es bastante satisfactorio con un AUN del 93 %

Análisis de conglomerados

El análisis de conglomerados es una técnica de análisis exploratorio, que busca separar la muestra en grupos (William R. Dillon, 1984). Hay dos enfoques muy conocidos para el análisis de conglomerados, el primero es jerárquico y el segundo es k-means.

En el caso del jerárquico nos centraremos en algoritmos aglomerativos, esto es, cada observación comienza como un conglomerado, un grupo por si mismo, y en cada paso se une un conglomerado con otro según la distancia entre uno y el otro.

El enfoque de k-means (o k-medias) consiste en escoger un número de grupos seleccionar centros al azar y clasificar




Figura 7: Curva ROC del conjunto de prueba




Figura 8: Dendrograma enlace completo

al centro más cercano, recalculamos el centro y repetimos hasta que no suceda cambio alguno.

Enfoque jerárquico

Los algoritmos jerárquicos aglomerativos parten de una matriz de «distancias» entre observaciones con entradas

$$D_{ij} = J(\hat{h}_i, \hat{h}_j)$$

donde $J(\hat{h}_i, \hat{h}_j) = I(\hat{h}_i, \hat{h}_j) + I(\hat{h}_j, \hat{h}_i)$. La métrica J cumple las propiedades de una distancia, exceptuando la desigualdad del triángulo.

Algunos métodos requieren definir distancias entre conglomerados, métodos de enlace completo y singular. Y otros reducir una función objetivo como lo es el método de Ward.

En la figura 8 presentamos el dendrograma que resulta de aplicar la metodología de enlace completo. Los puntos inferiores indican a qué clase pertenecen las observaciones. Los puntos color vino indican **gatos** y los puntos azules **perros**, notamos que las observaciones están muy mezcladas, esto es, si hacemos un corte a 3 conglomerados tendríamos un conglomerado con una mezcla de 124 observaciones de gatos con 111 de perros. Incluso si cortamos a 5 conglomerados, habría un conglomerado con 63 gatos y 97 perros.

Otro método es mínima varianza de Ward, el cual consiste en agregar conglomerados de tal modo que el aumento en la suma de errores cuadráticos de cada observación a la media del conglomerado al que pertenecen sea mínima. Es




Figura 9: Dendrograma Ward

decir, busca minimizar el incremento en la siguiente función objetivo

$$\sum_{k=1}^n \sum_{i=1}^{n_k} \sum_{j=1}^{n_k} d(x_i, x_j)^2 = \sum_{k=1}^n \sum_{i=1}^{n_k} d(x_i, \bar{x}_k)^2$$

Donde k es el número de conglomerados, n_k el número de elementos en el conglomerado. Ahora bien, la igualdad no

cumple para cualquier distancia d , particularmente es valida para la distancia euclidiana.

La figura 9 presenta el dendograma que resulta de aplicar esta metodología y los cambios se presentan en la tabla , donde notamos que hay tres conglomerados donde predominan los mininos, y otro donde predominan los perros, pero contiene mezclado 24 gatos.

	1	2	3	4
Gatos	24	49	76	15
Perro	99	1	9	4

De esos gatos que se cuean en el grupo 1 algunos tienen características como discos rayados (cat_167.wav, cat_165.wav), o combinaciones con otros sonidos, tienen mucho ruido (cat_81.wav, cat_82.wav). Si gráficamos la densidad espectral del grupo 1, figura 10, notamos que es muy similar a la que obtuvimos del conjunto de entrenamiento en el ejercicio de clasificación, figura 6.




Figura 10: Espectro conglomerado 1

En cambio, si observamos las densidades espectrales de los grupos 2 y 3, figuras 11 y 12 respectivamente, parece que se descompone el resultado del conjunto de entrenamiento de los gatos, figura 5, en 2 partes, e incluso si obtenemos el espectro promedio al juntar los 2 grupos, figura 13, tiene una forma más parecida a 5. Esto sugiere que el grupo de gatos puede tener 2 subgrupos con características distintas, ronroneos y maullidos. O gatos chicos y mayores.[por actualizar y verificar].




Figura 11: Espectro conglomerado 2




Figura 12: Espectro conglomerado 3

K-medias

El algoritmo de k-medias consiste en escoger el número de grupos k . El siguiente paso es escoger k de los elementos de la muestra, y tomarlos como centros, $\hat{\mu}_{s1} = \hat{h}_r$, donde $\hat{\mu}_{s1}$ es el centro del s -ésimo conglomerado en la primera iteración y \hat{h}_r es el estimador de la densidad espectral de la r -ésimo serie de tiempo.

El siguiente paso es clasificar en el centro más cercano




Figura 13: Espectro conglomerados 2 y 3 juntos




Figura 14: Densidad conglomerado 1

esto es clasificar \hat{f} en el conglomerado s si

$$I(\hat{\mu}_{s1}, f) \leq I(\hat{\mu}_{j1}, f), j = 1, \dots, k$$

Luego debemos obtener recalculamos las medias

$$\hat{\mu}_{s2} = \sum_{i=1}^{n_s} \hat{h}_s i$$

donde $\hat{\mu}_{s2}$ es el centro del s -ésimo conglomerado en la segunda iteración, $\hat{h}_s i$ es la densidad espectral de la i -ésima serie de tiempo en el s -ésimo conglomerado. Se reclasifican a los centros más cercanos. Repetimos estos pasos hasta que no haya cambios en la clasificación.

Para nuestro ejemplo, tomamos $k = 2$ para observar si el análisis de conglomerados separa en las 2 clases originales gatos y perros. Las figura 14 y 15 muestran las densidades espectrales del conglomerado 1 y el conglomerado 2 respectivamente.

El primer conglomerado tiene un aspecto similar a la respectiva con el grupo de gatos, y la segunda con el grupo de perros.

Lo anterior se reafirma observando la clasificación resultante, un conglomerado con 128 gatos y 12 perros, y otro compuesto de 101 perros y 36 gatos, si midieramos la tasa de error sería del 20% .




Figura 15: Densidad conglomerado 2

Referencias

- Corduas Marcella, P. D. (2008). *Time series clustering and classification by the autoregressive metric*.
- J. Yuan, Y. Z. (2000). *Spectral analysis of combustion noise and flame pattern recognition*.
- Kullback, S. (1978). *Information theory and statistics*. Dover Publications.
- marc moreaux. (2017). *Audio cats and dogs, classify raw sound events*. <https://www.kaggle.com/>

mmoreaux/audio-cats-and-dogs/home.

([Online; Obtenido 04-Noviembre-2018])

- Naoya Takahashi, B. P., Michael Gygli, y Gool, L. V. (2016). *Deep convolutional neural networks and data augmentation for acoustic event recognition*.
- Priestley, M. B. (1981). *Spectral analysis and time series*. Academic Press.
- Saeed Aghabozorgi, T. Y. W., Ali Seyed Shirkhorshidi. (2015). *Time-series clustering – a decade review*.
- Shumway, R. H. (2003). *Time-frequency clustering and discrimination analysis*.
- William R. Dillon, M. G. (1984). *Multivariate analysis*. Wiley.
- Yoshihide Kakizawa, M. T., Robert H. Shumway. (1998). *Discrimination and clustering for multivariate time series*.

1. Anexo 1, muestra

cat_1.wav	cat_10.wav	cat_100.wav
cat_101.wav	cat_102.wav	cat_105.wav
cat_107.wav	cat_108.wav	cat_109.wav
cat_11.wav	cat_110.wav	cat_113.wav
cat_114.wav	cat_115.wav	cat_118.wav
cat_119.wav	cat_121.wav	cat_122.wav
cat_123.wav	cat_124.wav	cat_126.wav
cat_127.wav	cat_128.wav	cat_129.wav
cat_130.wav	cat_131.wav	cat_132.wav
cat_133.wav	cat_134.wav	cat_135.wav
cat_137.wav	cat_139.wav	cat_14.wav
cat_140.wav	cat_142.wav	cat_143.wav
cat_146.wav	cat_147.wav	cat_148.wav
cat_15.wav	cat_151.wav	cat_152.wav
cat_153.wav	cat_154.wav	cat_156.wav
cat_157.wav	cat_158.wav	cat_159.wav
cat_16.wav	cat_161.wav	cat_162.wav
cat_163.wav	cat_164.wav	cat_165.wav
cat_167.wav	cat_17.wav	cat_18.wav
cat_19.wav	cat_23.wav	cat_25.wav
cat_26.wav	cat_27.wav	cat_28.wav
cat_3.wav	cat_30.wav	cat_31.wav
cat_32.wav	cat_33.wav	cat_34.wav
cat_35.wav	cat_36.wav	cat_37.wav
cat_39.wav	cat_4.wav	cat_40.wav
cat_41.wav	cat_42.wav	cat_43.wav
cat_44.wav	cat_48.wav	cat_51.wav
cat_54.wav	cat_56.wav	cat_57.wav
cat_6.wav	cat_61.wav	cat_62.wav
cat_64.wav	cat_68.wav	cat_69.wav

cat_7.wav	cat_71.wav	cat_72.wav
cat_73.wav	cat_75.wav	cat_76.wav
cat_78.wav	cat_79.wav	cat_80.wav
cat_81.wav	cat_82.wav	cat_84.wav
cat_85.wav	cat_86.wav	cat_87.wav
cat_88.wav	cat_90.wav	cat_91.wav
cat_92.wav	cat_93.wav	cat_95.wav
cat_96.wav	cat_97.wav	cat_98.wav
cat_99.wav		

Cuadro 1: Gatos en el conjunto de entrenamiento

dog_barking_101.wav	dog_barking_102.wav
dog_barking_105.wav	dog_barking_107.wav
dog_barking_108.wav	dog_barking_110.wav
dog_barking_111.wav	dog_barking_12.wav
dog_barking_13.wav	dog_barking_14.wav
dog_barking_16.wav	dog_barking_17.wav
dog_barking_19.wav	dog_barking_2.wav
dog_barking_20.wav	dog_barking_22.wav
dog_barking_23.wav	dog_barking_24.wav
dog_barking_25.wav	dog_barking_27.wav
dog_barking_29.wav	dog_barking_30.wav
dog_barking_31.wav	dog_barking_33.wav
dog_barking_36.wav	dog_barking_37.wav
dog_barking_4.wav	dog_barking_41.wav
dog_barking_45.wav	dog_barking_46.wav
dog_barking_49.wav	dog_barking_50.wav
dog_barking_53.wav	dog_barking_54.wav
dog_barking_55.wav	dog_barking_56.wav
dog_barking_58.wav	dog_barking_59.wav
dog_barking_6.wav	dog_barking_62.wav
dog_barking_66.wav	dog_barking_67.wav

dog_barking_68.wav	dog_barking_7.wav
dog_barking_72.wav	dog_barking_74.wav
dog_barking_75.wav	dog_barking_76.wav
dog_barking_79.wav	dog_barking_80.wav
dog_barking_81.wav	dog_barking_83.wav
dog_barking_84.wav	dog_barking_85.wav
dog_barking_86.wav	dog_barking_87.wav
dog_barking_88.wav	dog_barking_89.wav
dog_barking_9.wav	dog_barking_90.wav
dog_barking_91.wav	dog_barking_95.wav
dog_barking_98.wav	dog_barking_99.wav
<u>dog_barking_4.wav</u>	<u>dog_barking_72.wav</u>
<u>dog_barking_14.wav</u>	<u>dog_barking_89.wav</u>
<u>dog_barking_12.wav</u>	<u>dog_barking_99.wav</u>
<u>dog_barking_66.wav</u>	<u>dog_barking_30.wav</u>
dog_barking_108.wav	<u>dog_barking_25.wav</u>
<u>dog_barking_29.wav</u>	<u>dog_barking_33.wav</u>
<u>dog_barking_95.wav</u>	<u>dog_barking_59.wav</u>
<u>dog_barking_72.wav</u>	<u>dog_barking_14.wav</u>
<u>dog_barking_55.wav</u>	<u>dog_barking_75.wav</u>
<u>dog_barking_49.wav</u>	<u>dog_barking_75.wav</u>
<u>dog_barking_105.wav</u>	<u>dog_barking_45.wav</u>
<u>dog_barking_110.wav</u>	<u>dog_barking_14.wav</u>
<u>dog_barking_25.wav</u>	<u>dog_barking_27.wav</u>
dog_barking_108.wav	<u>dog_barking_59.wav</u>
<u>dog_barking_55.wav</u>	dog_barking_22.wav
<u>dog_barking_84.wav</u>	<u>dog_barking_31.wav</u>
dog_barking_22.wav	dog_barking_111.wav
<u>dog_barking_85.wav</u>	<u>dog_barking_37.wav</u>
<u>dog_barking_91.wav</u>	<u>dog_barking_33.wav</u>
<u>dog_barking_16.wav</u>	<u>dog_barking_12.wav</u>
<u>dog_barking_74.wav</u>	<u>dog_barking_23.wav</u>
<u>dog_barking_58.wav</u>	<u>dog_barking_76.wav</u>
<u>dog_barking_56.wav</u>	<u>dog_barking_25.wav</u>
<u>dog_barking_99.wav</u>	<u>dog_barking_74.wav</u>
dog_barking_107.wav	<u>dog_barking_74.wav</u>
<u>dog_barking_13.wav</u>	

Cuadro 2: Perros en el conjunto de entrenamiento, los archivos subrayados son los resultados del remuestreo.

cat_103.wav	cat_106.wav	cat_112.wav
cat_116.wav	cat_117.wav	cat_12.wav
cat_120.wav	cat_125.wav	cat_13.wav
cat_136.wav	cat_138.wav	cat_141.wav
cat_144.wav	cat_149.wav	cat_150.wav
cat_155.wav	cat_160.wav	cat_166.wav
cat_2.wav	cat_20.wav	cat_21.wav
cat_22.wav	cat_24.wav	cat_29.wav
cat_38.wav	cat_45.wav	cat_46.wav
cat_47.wav	cat_49.wav	cat_5.wav
cat_50.wav	cat_52.wav	cat_53.wav
cat_55.wav	cat_58.wav	cat_59.wav
cat_60.wav	cat_63.wav	cat_65.wav
cat_66.wav	cat_67.wav	cat_70.wav
cat_74.wav	cat_77.wav	cat_8.wav
cat_83.wav	cat_89.wav	cat_9.wav
cat_94.wav		

Cuadro 3: Gatos en el conjunto de prueba

dog_barking_0.wav	dog_barking_1.wav
dog_barking_10.wav	dog_barking_100.wav
dog_barking_103.wav	dog_barking_104.wav
dog_barking_106.wav	dog_barking_109.wav
dog_barking_11.wav	dog_barking_112.wav
dog_barking_15.wav	dog_barking_18.wav
dog_barking_21.wav	dog_barking_26.wav
dog_barking_28.wav	dog_barking_3.wav
dog_barking_32.wav	dog_barking_34.wav
dog_barking_35.wav	dog_barking_38.wav
dog_barking_39.wav	dog_barking_40.wav
dog_barking_42.wav	dog_barking_43.wav
dog_barking_44.wav	dog_barking_47.wav
dog_barking_48.wav	dog_barking_5.wav
dog_barking_51.wav	dog_barking_52.wav
dog_barking_57.wav	dog_barking_60.wav
dog_barking_61.wav	dog_barking_63.wav
dog_barking_64.wav	dog_barking_65.wav
dog_barking_69.wav	dog_barking_70.wav
dog_barking_71.wav	dog_barking_73.wav
dog_barking_77.wav	dog_barking_78.wav
dog_barking_8.wav	dog_barking_82.wav
dog_barking_92.wav	dog_barking_93.wav
dog_barking_94.wav	dog_barking_96.wav
dog_barking_97.wav	

Cuadro 4: Perros en el conjunto de prueba